

ANÁLISE DA DINÂMICA ENTRE PREÇOS DAS *COMMODITIES* E INFLAÇÃO NO BRASIL UTILIZANDO FATORES COMUNS E PREVISÕES FORA DA AMOSTRA PARA O PERÍODO DE 2003:02 À 2014:02

Rodrigo Gustavo de Souza¹

Resumo: O presente artigo analisou relação entre os preços das *commodities* e inflação no Brasil. O objetivo é verificar se a inclusão dos fatores contidos nos índices de *commodities* melhora o desempenho preditivo de um modelo para inflação que contenha somente variáveis macroeconômicas para o Brasil no período de 2003 a 2014. Para isto a metodologia empregada foi o uso de fatores comuns e previsões dentro e fora da amostra. Uma das principais vantagens da análise é que a utilização de fatores comuns possibilita capturar componentes não observáveis do conjunto de dados, ao mesmo tempo em que possibilita utilizar um grande número de observações em modelos tipo VAR.

Palavras - chave: Preços de *commodities*; Inflação, Fatores comuns; Previsões.

Abstract: This paper analyzes the relationship between commodity prices and inflation in Brazil. The goal is to verify that the inclusion of the factors contained in commodity indexes improves the predictive performance of a model for inflation that contains only macroeconomic variables for Brazil in the period 2003-2014. We use the methodology of common factors and forecasts in and out-of-sample. The usage of common factors enables us to capture unobservable components of the data and, at the same time, allows the use of a large number of observations on VAR type models.

Keywords: Commodity prices; Inflation, Common factors; Forecasts.

Área 4 - Macroeconomia, Economia Monetária e Finanças

Classificação JEL: E31, E37, F41 e F47.

¹Doutorando em Economia (IE/UFRJ) e bolsista da FAPERJ.

1 INTRODUÇÃO

Na literatura existe uma gama de trabalhos que tratam da relação entre preços de *commodities* e inflação. Os trabalhos pioneiros têm origem na década de 1970, quando discutiam se os preços das *commodities* eram bons indicadores antecedentes da inflação. Entre os trabalhos pioneiros vale ressaltar os trabalhos de Garner (1985, 1989), Marquis e Cunnengham (1990), Cody e Mills (1991), entre outros, corroboram a relação causal dos preços das *commodities* para a inflação.

Esta relação dos preços das *commodities* e inflação se mostrou muito forte na década de 1970, todavia a partir de meados da década de 1980 esta relação se enfraqueceu, e os preços das *commodities* que eram considerados bons indicadores antecedentes da inflação, mostraram-se indicadores pobres para prever a inflação no início da década de 1980. Isto ocorreu devido aos canais nos quais os preços das *commodities* sinalizam a inflação não estavam mais operando de forma adequada, assim como eles fizeram no passado: bens tornaram-se menos importante como insumo para a produção, alguns dos sinais de inflação de preços de *commodities* podem ser esterilizados por compensação política monetária, e produtos tornaram-se menos popular como uma proteção contra a inflação (BLOOMBERG; HARRYS, 1995).

Outra questão refere-se que qualquer *commodity*, está sujeita a choques idiossincráticos, como choques de oferta que elevam os preços das *commodities* podendo conduzir a um aumento de preços gerais da economia. Todavia o efeito observado vai depender da relativa importância da mercadoria que está sofrendo o choque e da flexibilidade dos outros preços, assim os preços das *commodities* afetadas seriam maiores do que o efeito sobre os preços globais, o que significa que a relação entre o nível de preços das *commodities* que sofreram o choque e o nível geral de preços globais seria distorcida, de forma que haveria mudança de relação entre eles (FURLONG; INGENITO, 1996).

A discussão entre os preços das *commodities* e inflação ganhou uma nova abordagem na década de 1980, no que se refere ao uso dos preços das *commodities* na formulação ou condução da política monetária. Contudo com a perda da importância dos preços das *commodities* para prever a inflação na década de 1980, esta discussão perdeu importância. Os trabalhos recentes a respeito dos preços das *commodities* como Awokuse e Yang (2003), Bhar e Hamori (2008), Cheung (2009), Hassam e Salim (2011), Ciner (2011), Gospodinov e Ng (2013), entre outros, mostraram evidências que os preços das *commodities* são bons indicadores antecedentes da inflação, da produção industrial e taxa de juros, desta forma os preços das *commodities* podem ser usados no mínimo como uma variável informacional para a condução da política monetária.

O principal argumento na literatura a favor da utilização de preços de *commodities* decorre do fato de que as *commodities* são negociadas em mercados de leilões contínuos. Conseqüentemente, proponentes argumentam que os preços das *commodities* fornecem informações instantâneas sobre o estado da economia. O aumento dos preços das *commodities*, por exemplo, sinaliza que a economia real está crescendo muito rapidamente e, portanto, a inflação poderá acelerar. Uma resposta automática ao aumento dos preços das *commodities* levaria a uma política monetária mais restritiva e prevenção da aceleração da inflação (CODY; MILLS, 1991).

A crítica a este argumento é que os preços das *commodities* não podem ser usados efetivamente na formulação da política monetária porque estão sujeitos a grandes choques específicos de mercado que não têm implicações macroeconômicas (MARQUIS E CUNNINGHAM, 1990; CODY E MILLS, 1991). Dentro de uma visão monetarista tradicional Bessler (1984), Pindyck e Rotemberg (1990); Hua (1998) argumentaram que os movimentos de preços de *commodities* são pelo menos em parte, o resultado de fatores macroeconômicos e que a causalidade deveria ser pensada a partir de variáveis macroeconômicas para os preços das *commodities*².

Frankel (2006) analisa a influência da política monetária nos preços das *commodities*. O seu argumento central é que alto preço real das *commodities* pode ser um sinal de política monetária fraca.

²Barsky e Kilian (2001), entretanto, contestam essa visão e argumentam que o aumento dos preços das *commodities* durante a década de 1970 foi resultado da política monetária.

Assim, questiona os argumentos que os preços das *commodities* seriam bons indicadores antecedentes da inflação, na medida em que as taxas reais de juros juntos com outros fatores determinam os preços reais das *commodities*. Contrapondo à maioria dos estudos na literatura, em que os preços das *commodities* afetam as variáveis de política monetária, o autor mostra que as decisões de política monetária podem afetar os preços das *commodities*. O argumento é que as altas taxas de juros reduzem a demanda por *commodities* armazenáveis, ou aumentam a oferta, através de uma variedade de canais, assim conduzindo a uma redução dos preços das *commodities*.

Gospodinov e Ng (2013) desenvolvem um sistema para analisar os preços das *commodities* e inflação nos Estados Unidos e nos países do G-7 (Canadá, Japão, Alemanha, França, Itália e Reino Unido). A premissa básica é que rendimentos de conveniência (o benefício de usar a mercadoria armazenada sempre que desejado, no caso ter as *commodities* em “mãos” quando precisar), contêm informações sobre os preços das *commodities* e os preços das *commodities* antecipam a inflação. Os autores desenvolvem um modelo que estabelece uma relação entre os preços das *commodities* e os rendimentos de conveniência do qual a relação entre inflação e rendimentos de conveniência é obtida. Os principais resultados é que os componentes principais dos rendimentos de conveniência individuais incorporaram informações úteis para a previsão da inflação e dos preços das *commodities*. O fato de que os componentes principais dos rendimentos de conveniência explicam tanto a inflação como o índice de preços de *commodities* do FMI, mas que este último só tem fraco poder preditivo para a inflação é o que reforça o ponto de que os preços das *commodities* têm várias fontes de variação e não são todas que tem consequências inflacionárias.

A problemática trazida pela literatura refere-se ao potencial poder preditivo dos preços das *commodities* para prever a inflação. Objetivo do presente artigo é verificar se a inclusão dos fatores contidos nos índices de *commodities* melhora o desempenho preditivo de um modelo para inflação que contenha somente variáveis macroeconômicas para o Brasil no período de janeiro de 2003 a fevereiro de 2014.

Os modelos de fatores têm como vantagem em relação aos modelos tradicionais o fato que eles poderiam melhorar o poder preditivo, na medida em que possibilitam reduzir uma grande quantidade de séries a pequenos números de fatores e assim evitando uma parametrização em modelos do tipo VAR. Outra característica importante é que os fatores possibilitam capturar características não observáveis das séries.

Na literatura existem vários trabalhos que utilizam fatores para previsão de variáveis macroeconômicas. Vale ressaltar os trabalhos de Stock e Watson (1998, 2002a, 2002b) que consideram a previsão de uma série usando um grande número de séries preditoras. Para previsões macroeconômicas, o número de séries candidata a preditores (N) pode ser muito grande, frequentemente maior do que o número de observações das séries no tempo (T) disponível para ajustamento do modelo. Este problema de alta-dimensionalidade é simplificado através da modelação da covariabilidade da série em termos de um número relativamente pequeno de fatores latentes não observados. Banerjee, Marcellino e Masten (2008) utilizam métodos baseados em índices de difusão em amostras curtas com mudança estrutural para prever variáveis macroeconômicas na área do euro e Eslovênia.

Para o Brasil, entre os trabalhos realizados tem-se Ferreira (2005) que busca prever o PIB trimestral do Brasil através de um modelo de índice de difusão; Ferreira, Oliveira Júnior e Castelar (2012) usam o modelo de índice de difusão para prever a taxa de crescimento do PIB agrícola brasileiro; Almeida, Alves e Lima (2012) estimaram impactos dos choques exógenos na política monetária e no câmbio sobre variáveis econômicas brasileiras, utilizando um modelo *Factor-Augmented Vector Autoregression* (FAVAR), Maeda Junior (2012) usa uma abordagem combinada entre o modelo de fator de correção de erros e fatores extraídos de grandes conjuntos de dados para verificar se melhora a previsão da taxa de juros no Brasil, em relação a modelos como VAR, VEC e FAVAR, Felício e Rossi Júnior (2014) utiliza um modelo de fator para explicar a dinâmica da taxa de câmbio Real/Dólar Norte-Americano.

Para alcançar o objetivo proposto, o presente artigo está dividido em três seções, além desta introdução e das considerações finais. Na segunda seção é feita uma descrição do modelo e dos dados que serão utilizados. Na terceira seção, são extraídos os fatores comuns e feita uma análise da relação dos

fatores com as variáveis originais. Na quarta seção são realizados os exercícios econométricos de previsão dentro e fora da amostra. Por fim, a quinta e última seção são feitas as considerações finais.

2 MODELOS PARA PREVISÃO DA INFLAÇÃO COM BASE NO ÍNDICE DE *COMMODITIES*

Dado o forte aumento dos preços das *commodities* cujo auge foi entre 2003 a 2008 e, o fato de que a participação relativa dos produtos não industriais na pauta de exportações brasileiras praticamente dobrou – de acordo com o Ministério do Desenvolvimento, Indústria e Comércio (2013) passou de 19%, em 2002, para 40% em 2012, é de fundamental importância analisar quais os efeitos dos preços das *commodities* sobre a inflação no Brasil.

Países em que os preços das *commodities* têm um impacto considerável nas exportações, mudanças dos preços das *commodities* podem levar a um aumento na receita de exportação, pois por um lado tem um aumento do valor das exportações e por outro pode haver uma apreciação da taxa de câmbio conduzindo a uma redução da quantidade de exportação. Caso o efeito líquido seja positivo, haverá um aumento da renda nacional, aumentando a demanda agregada e uma maior demanda agregada aumenta a produção, o emprego e o nível de preços.

A relação entre os preços das *commodities* e o aumento da inflação de preços ao consumidor surge através de vários canais. Em primeiro lugar, as extensões que os preços das *commodities* aumentam refletem a aceleração da demanda por bens finais globais, eles podem alimentar pressões inflacionárias domésticas (internas), dependendo do grau de abertura da economia, isto ocorre por que a demanda por bens finais aumenta a demanda por matérias primas e insumos. Em segundo lugar, as *commodities* são importantes insumos para a produção e, portanto, se os aumentos de preços de *commodities* são suficientemente persistentes para influenciar as expectativas de inflação, os agentes podem repassar o aumento dos custos dos insumos na forma de uma inflação mais elevada de bens finais. Como os preços das *commodities* são determinados nos mercados de leilões contínuos, eles respondem instantaneamente às expectativas sobre a oferta e a demanda, enquanto os preços ao consumidor ajustam de forma mais lenta. Isto permite preços das *commodities* darem uma advertência antecipada de pressões inflacionárias, mesmo quando a demanda se origina na fase bens finais. Em terceiro lugar, como as *commodities* são armazenáveis, a demanda de estoque é influenciada pelos preços futuros esperados, e os preços das *commodities*, portanto contém um elemento *forward-looking*. Por último, uma vez que os preços das *commodities* respondem rapidamente às pressões gerais de inflação, os investidores podem ver eles como um *hedge* contra a inflação (GARNER, 1989; BLOOMBERG E HARRYS, 1995; CHEUNG, 2009).

Os modelos de tomada de decisões de política monetária pelo Banco Central do Brasil (BACEN) têm como estrutura básica é constituída por uma curva de Phillips para a inflação de preços livres, a qual representa o lado da oferta da economia; uma curva IS descrevendo a dinâmica do hiato do produto e representando a demanda agregada e uma equação que descreve a inclinação da estrutura a termo da taxa de juros (BACEN, 2011).

Dada a literatura a respeito de preços das *commodities* e inflação e a estrutura dos modelos do BACEN é possível definir o seguinte modelo base para a previsão da inflação com base nos índices de preços das *commodities*.

$$\pi_t = \alpha + \beta_1 \pi_{t-p} + \phi_2 \pi_{t+h}^e + \gamma_3 y_{t-p} + \psi_4 PC_{t-p} + \delta_5 EP + \mu_t \quad (1)$$

Onde $p = 1, \dots, n$

O modelo é composto pela inflação presente (π_t), inflação passada (π_{t-p}), choques de oferta e demanda. Como choque de demanda tem-se taxa de variação do hiato do produto (y_{t-p}), os choques de oferta são dados pelos índices de preços das *commodities* (PC_{t-p}) e a taxa de câmbio efetiva real (EP), sendo que são consideradas diferentes especificações para os preços das *commodities* (PC). Assim serão estimados dois modelos bases, sendo que o primeiro será usado o índice de *commodities* geral do FMI e o segundo será usado fatores comuns dos índices de *commodities* do FMI e desta forma será feita uma

comparação em termos de poder preditivo dos modelos para avaliar a importância da utilização dos fatores.

2.1 DADOS

Esta seção discute os dados usados na parte empírica. O período a ser analisado corresponde de janeiro de 2003 a fevereiro de 2014. Os dados são mensais, abrangendo um total de 134 observações e 14 séries, sendo que 10 séries referem-se a preços de *commodities*, separados por subgrupos³ e as outras variáveis são de controle.

O componente inercial e expectacional do modelo que são representadas pelas séries do índice da variação mensal do Índice de Preços ao consumidor (IPCA), e a expectativa média de inflação anualizada, são obtidas respectivamente ao Instituto Brasileiro de Geografia e Estatística (IBGE) e ao Banco Central do Brasil (BCB), ambas são expressas em taxas através da transformação das séries na diferença do logaritmo⁴. Os choques de demanda são representados pelo hiato do Índice de Atividade Econômica do Banco Central (IBC-Br) com ajusta sazonal e sua tendência. A tendência é obtida com o uso do filtro Hodrick-Prescott (HP). O parâmetro de alisamento para o filtro HP é ajustado para seu valor padrão 14.400 para os dados mensais. Assim, o hiato do IBC-Br é obtido a partir do desvio do IBC-br com ajuste sazonal menos a sua tendência. Como o hiato tem valores negativos, acrescentou-se uma constante a série depois transformou a série na diferença do logaritmo.

O choque de oferta é usado o índice de preços de *commodities* fornecido pelo Fundo Monetário Internacional (FMI), estes índices são divididos em subgrupos. Desta forma tem-se índice de *commodities* total, não energia (inclui todas as *commodities*, exceto as de energia), alimentos e bebidas, alimentos (inclui índice de preços de cereais, óleos vegetais, carne, frutos do mar, açúcar, bananas e laranjas), bebidas (inclui café, chá e cacau), insumos industriais (inclui índice de preços de matérias primas agrícolas e índice de preços de metais), matérias primas agrícolas (inclui índice de preços da madeira, algodão, lã, borrachas e couro cru), Metais (inclui índice de preços de cobre, alumínio, minério de ferro, estanho, níquel, zinco, chumbo e urânio) e preços de energia (inclui índice de preços de petróleo, gás natural e carvão). Além do índice de preços das *commodities* a taxa de câmbio efetiva real deflacionada pelo IPCA é usada como choque de oferta. As descrições das séries encontram-se na Tabela A.1 do Apêndice A.

O período a ser analisado foi escolhido devido a sua relevância, pois do período de 2003 até 2008, houve um dos maiores aumentos dos preços das *commodities* no mercado mundial e posteriormente a partir de meados de 2008, houve uma drástica queda de corrente da crise americana *subprime*. A partir de 2009 novamente houve uma recuperação dos preços das *commodities*, todavia não no mesmo patamar, no qual seguiu-se novamente um processo de recuperação até 2011, quando novamente ocorreu outra queda nos preços e posteriormente seguiu-se novamente uma recuperação de preços.

A evolução dos preços das *commodities*, como pode se verificar, elas obtiveram um forte crescimento entre o período de 2003 a 2008, este crescimento pode ter sido principalmente pela forte crescimento da demanda mundial por *commodities*, tendo a China como um dos principais compradores e consumidores de *commodities* mundiais, principalmente grãos e metais. Todavia, a partir de meados de 2008, com a crise do *subprime* que se iniciou nos Estados Unidos da América (EUA) e se espalhou por todo o mundo, houve uma crise de grandes proporções que ocasionou uma redução da demanda das *commodities* e conseqüentemente dos preços, o que compensou em parte a depreciação da taxa de câmbio no período. No início de 2009, os preços das *commodities* ameaçaram uma recuperação dos preços, contudo, esta recuperação não foi rápida e durou até início de 2011, quando novamente a crise se instalou decorrente principalmente deteriorização fiscal de países europeus.

³Os dados sobre a taxa de câmbio, taxa de juros, variação da inflação e índices de preços das *commodities* pode ser obtidos para *downloading* em:

<http://www.ipeadata.gov.br>, <https://www3.bcb.gov.br/sgspub/localizarseries/localizarSeries.do?method=prepararTelaLocalizarSeries> e <http://www.imf.org/external/np/res/commmod/index.aspx>.

⁴ Como a série variação do IPCA mensal tem valores negativos, acrescentou-se a constante (1), antes de transformar a série na diferença do logaritmo.

Como pode se observar o período de maior aumento do índice de preços das *commodities* pode verificar que a inflação (IPCA), teve um significativo aumento. As variáveis macroeconômicas tiveram um comportamento parecido no que se refere ao comportamento dos preços das *commodities*, o hiato do produto mostrou uma tendênciacrescente, acompanhando o bom desempenho dos preços das *commodities*, acompanhado pela redução da taxa de desemprego. Neste período também verifica uma forte apreciação da taxa de câmbio, em parte decorrente do aumento dos preços das *commodities* no mercado internacional no qual evidenciou ganhos nos termos de troca e em parte pela elevada taxa de juros reais do período, no qual continuou incentivando a entrada de capital especulativo.

3 EXTRAÇÃO DOS FATORES COMUNS

O passo inicial da análise é determinar o método de extração dos fatores. O corpo da literatura referente ao modelo de fatores é extenso, os primeiros modelos de fatores referem-se aos trabalhos Geweke (1977), Sims e Sargent (1977 apud STOCK e WATSON, 1998) que analisaram este modelo usando domínio de frequência para um pequeno número de variáveis. Entre os trabalhos mais recentes, destacam-se os trabalhos de Stock e Watson (1998, 2002), Forni *et al.* (2000, 2005), Bai e Ng (2008), entre outros trabalhos.

Uma abordagem alternativa é a modelo de espaço estado, que também pode ser usado para extrair movimentos comuns entre um conjunto de séries temporais agregadas. Cayen (2010) analisa os movimentos da taxa de câmbio através da de um painel de taxa de câmbio, usando a metodologia de modelo de fator dinâmico ortogonal e também usando modelo de espaço estado.

Definida a metodologia de extração dos fatores é necessário determinar o número de fatores. Na literatura vale ressaltar três metodologias para determinar número de fatores, a saber: a metodologia proposto por Stock e Watson (1998), Bai e Ng (2002) e o critério Kaiser-Guttman, que diz que só os fatores com autovalor maior do que 1 deve ser mantido.

O primeiro considera que o número k maiores fatores, de forma que $k \ll r$, onde k são os fatores estimados e r os fatores verdadeiros. Desta forma são utilizados os k maiores fatores, tendo como base o erro médio quadrado (SME), usando um critério de informação. Por outro lado, Bai e Ng (2002), desenvolvem o método de determinação de fatores através do uso de um critério segundo o qual a uma penalização à medida que acrescenta fatores desnecessários, desta forma a uma penalidade pelo super ajustamento do modelo.

Por fim, o último critério, considera o número de fatores retidos deve ser grande o suficiente para dar conta da maior parte da variação comum na amostra, mas pequena o suficiente para descartar fatores que basicamente representam movimentos idiossincráticos nos dados. Um critério comum para a série de fatores a ser considerado é o critério Kaiser-Guttman, que diz que só os fatores com autovalor maior do que 1 deve ser mantido (CAYEN, 2010).

No presente trabalho será usado o método de extração de fatores ortogonais⁵ e o critério do número de fatores será baseado no critério de Kaiser-Guttman. A Tabela 1 mostra a variância acumulada explicada por n fatores.

⁵Na Tabela A.2 do Apêndice A, encontra-se a estatísticas descritivas das séries dos índices de *commodities* (média, desvio padrão e matriz de correlação). Como pode verificar, as variáveis são altamente correlacionadas, favorecendo a análise de fatores.


Tabela 1 - Autovalores e percentual da variância explicada de cada componente

Autovalores				
Extração dos componentes principais				
Número de componentes	Autovalores	% da variância explicada	Autovalores Acumulados	% da variância acumulada
1	5.650308	62.78120	5.650308	62.78120
2	1.213315	13.48128	6.863623	76.26247
3	0.944647	10.49608	7.808270	86.75856
4	0.621973	6.91082	8.430244	93.66937
5	0.558618	6.20687	8.988862	99.87624
6	0.006341	0.07046	8.995203	99.94670
7	0.003783	0.04203	8.998986	99.98873

Fonte: elaboração própria com base em dados da pesquisa.


Analisando a Tabela 1, pode-se observar que os 2 (dois) primeiros fatores possuem autovalores, que correspondem a 62,79% e 13,49% da variância total explicada pelos autovalores do modelo, assim correspondendo a 76,27%, desta maneira os dois primeiros fatores juntos explicam 76,27% das variações da variáveis originais, assim será utilizado dois fatores para a análise seguindo o critério de Kaiser-Guttman.

O Gráfico 1, demonstra o percentual da variância dos índices de preços das *commodities* que é acumulada pelos primeiros n fatores.

**Gráfico1- Variância Acumulada explicada pelos n fatores para os Índices de *Commodities***

Fonte: elaboração própria com base em dados da pesquisa.

Outra forma de determinar o número de fatores é através do método gráfico. No Gráfico 2, tem-se a seleção dos componentes principais através do método gráfico *ScreePlot*. No eixo das ordenadas tem-se a porcentagem de variação explicada por cada componente e os autovalores estão representados em ordem decrescentes no eixo das abscissas.

**Gráfico 2 - Explicação da proporção de variação de cada componente principal**

Fonte: Elaboração própria com base em dados da pesquisa.

Com base no critério de Kaiser-Guttman e da análise gráfica, foi extraído dois fatores dos índices de *commodities*. O Gráfico 3, mostra a evolução dos fatores no tempo e sua relação com o a inflação.




Gráfico 3 - Evolução dos Fatores dos Índices de *Commodities* do Período de 2003:01 à 20014:02

Fonte: Elaboração própria com base em dados da pesquisa.

Como se pode observar, no período de 2003 a 2008, os fatores tiveram um movimento de ascensão, devido ao forte aumento dos preços das *commodities*, todavia a partir de 2008, com a crise americana, houve uma forte queda nos preços das *commodities*, esta queda é evidenciada através do movimento dos fatores no Gráfico 3. A partir de 2009, os preços das *commodities* retomaram sua trajetória de crescimento, todavia num ritmo de crescimento mais lento e com oscilações. Durante este período, pode se observar que a variação dos preços internos (IPCAvar) seguiu os movimentos dos preços das *commodities* de forma menos acentuada, evidenciando uma possível relação entre os movimentos dos preços das *commodities* e a inflação no Brasil neste período.

3.1 RELAÇÕES ENTRE OS FATORES COMUNS E AS VARIÁVEIS ORIGINAIS

O modelo de fatores possibilita reduzir um grande número de variáveis observáveis para um pequeno conjunto de fatores não observáveis, desta forma tem-se como vantagem poder utilizar uma grande quantidade de informações em modelo de previsão, cuja quantidade de variáveis poderia levar o modelo a uma parametrização. Todavia a grande desvantagem deste método consiste na dificuldade de interpretar estes fatores. Uma das formas de interpretar estes fatores é através das cargas fatoriais (*factor loading*). As cargas fatoriais correspondem à correlação entre a variável observada e o fator comum (REIS, 1997). A Tabela 2 mostra a correlação entre as variáveis observadas e os n fatores comuns.

Tabela 2 - Matriz de correlação entre as variáveis originais e as *n* componentes principaisCorrelação entre as variáveis observadas e *n* fatores escolhidos (*factorloading*).

	F1	F2
DLPNFUEL	-0.969804*	-0.092755
DLPFANDB	-0.818460*	-0.517217*
DLPFOOD	-0.802175*	-0.487247*
DLPBEVE	-0.546802*	-0.486590*
DLPINDU	-0.870999*	0.268742*
DLPRAWM	-0.668057*	0.300816*
DLPMETA	-0.823149*	0.222645*
DLPNRG	-0.783039*	0.351776*
DLPOILAPSP	-0.775739*	0.356356*

Fonte: Elaboração própria com base em dados da pesquisa.

Nota: Correlação significativa a *5%.

A Tabela 2 mostra a matriz de correlação entre as variáveis originais e as *n* componentes principais e a contribuição de cada variável em relação a cada fator. Os valores que estão em destaque representam de forma significativa a contribuição de cada variável em cada fator. Como se pode observar, para os fatores dos índices de *commodities*, todos os subgrupos de *commodities* tem uma contribuição importante. Vale ressaltar que o subgrupo de *commodities* alimentos é o que tem maior participação no primeiro e segundo fator.

Outra forma de identificar os fatores é através de uma matriz de correlação entre os fatores e variáveis explicativas do modelo. No Quadro 1, tem-se a matriz de correlação dos fatores e das variáveis de controle do modelo.

Correlação entre as variáveis explicativas e os <i>n</i> fatores escolhidos						
	F1	F2	Dlexpinfla	DLIPCavar	DLTCER	Dlhiato
F1	1.000000					
F2	0.000000	1.000000				
Dlexpinfla	0.052099	0.080938	1.000000			
DLIPCavar	-0.071460	-0.098134	0.013337	1.000000		
DLTCER	0.353389	0.052314	0.224058	0.061090	1.000000	
Dlhiato	-0.301436	0.245708	0.153155	0.038693	-0.166506	1.000000

Quadro 1 - Correlação entre as variáveis explicativas e os fatores escolhidos

Fonte: Elaboração própria com base em dados da pesquisa.

Nota: As correlações marcadas são significativas a $p < 0,5000$, para 133 observações.

No Quadro 1, tem-se a correlação entre os fatores dos índices de preços das *commodities* e algumas variáveis macroeconômicas fundamentais. Pode-se verificar que existe uma correlação positiva entre o Fator 1 (F1) e a taxa de câmbio efetiva real (TXCER), esta correlação é esperada na medida que o Brasil detém grande pauta de sua exportação baseada em *commodities*, desta maneira elevações dos preços das *commodities*, podem conduzir a apreciação da taxa de câmbio. Em relação ao hiato do produto, esta a correlação é ambígua, pois há uma correlação negativa entre o hiato do índice de atividade do Banco Central (IBC-br) e o F1, por outro lado a relação é positiva como relação ao segundo fator. Este

resultado não é totalmente inesperado, pois alguns canais da transmissão dos preços das *commodities* para os preços podem não estar funcionando, como ressaltado por (BLOOMBERG;HARRY, 1995).

4 PREVISIBILIDADE DA INFLAÇÃO E UTILIZAÇÃO DE FATORES COMUNS

No presente trabalho será examinada a dinâmica entre taxa de inflação, índice de preços de *commodities*, variáveis macroeconômicas fundamentais e fatores comuns como forma de capturar os efeitos e elementos não observáveis da amostra, tanto em termos de Causalidade de Granger e habilidade de previsão dentro (*in sample*) e previsão fora da amostra (*out-of-sample*). Segundo Chen, Rogoff e Rossi (2008), estes dois testes são importantes alternativas de abordagens para avaliar o conteúdo preditivo de uma variável.

Os testes na amostra tiram vantagem do tamanho total da amostra e, portanto, tendem a ter uma maior potência, enquanto que o processo de previsão para fora da amostra pode ser mais prático, uma vez que imita a restrição de dados de previsão em tempo real e é mais sensível aos problemas de má especificação. Como é bem conhecido na literatura, os testes preditivos dentro da amostra e fora da amostra (*out-of-sample*) podem muitas vezes fornecer conclusões diferentes, devido às suas diferenças no tratamento de parâmetros variáveis no tempo, a possibilidade de sobreajustamento, tamanhos de amostra e outros vieses (CHEN, ROGOFF E ROSSI, 2008, p.10-11).

O exercício econométrico se assemelha aos trabalhos de Chen, Rogoff e Rossi (2008), Farraro, Rogoff e Rossi (2012), Felício e Rossi Júnior (2012), que utilizaram diversas especificações de modelos de previsões dentro e fora da amostra. Cabe ressaltar o trabalho de Felício e Rossi Júnior (2014) que utiliza fatores para fazer previsões dentro e fora da amostra para diferentes horizontes.

Para iniciar as previsões dentro e fora da amostra, serão realizados testes de raiz unitários como forma de verificar se as séries seguem um processo estocástico estacionário, para este fim foi realizado três tipos diferentes de testes de raiz unitárias: Dickey-Fuller Aumentado (ADF), Phillips e Perron (PP) e Kwiatkowski, Phillips, Schmidt e Shin (KPSS).

O teste de Dickey-Fuller Aumentado (ADF), proposto por Said e Dickey (1984) inclui termos de diferença defasados e possui a vantagem de considerar a autocorrelação entre os resíduos. Phillips e Perron (1988)⁶ propõem um método (não paramétrico) de controle para correlação serial quando o teste de raiz unitária alternativa. O método PP estima a equação de teste DF não aumentada, e modifica a relação entre o coeficiente de correlação serial para que não afeta a distribuição assintótica da estatística de teste. Por último será realizado o teste KPSS (1992) como forma de robustez, pois ele difere dos testes de raiz unitária descritos, na medida que as séries são assumidas ter uma tendência estacionária sobre a hipótese nula, desta forma a hipótese do teste de raiz unitária é inversa ao dos testes ADF e PP.

⁶O teste de Phillips-Perron (PP), proposto por Phillips e Perron (1988), também objetiva identificar se as séries do modelo são estacionárias. Enquanto o teste ADF faz a correção para a maior ordem de correlação serial, por adicionar termos defasados diferenciados no lado direito da equação, o teste de Phillips-Perron faz uma correção para a estatística-t do coeficiente de regressão AR (1), considerando a correlação serial. A hipótese nula do teste PP é a mesma do teste ADF. Tanto para o teste ADF como para o teste PP, os valores críticos são os tabelados por Dickey-Fuller e MacKinnon (1991).

Tabela 3 - Testes de Raiz Unitária (ADF, PP e KPSS)

Variáveis	Teste de Raiz Unitária		
	ADF	PP	KPSS
Dlexpinfla	-9.614816*(5)	-5.376255*(6)	0.048249+N(1)
Dlhiato	-10.93273*(0)	-11.30826*(11)	0.035382+N(10)
dlipcavar	-12.82976*(0)	-16.43848*(16)	0.089041+N(11)
dlpallfnf	-7.591131*(0)	-7.650210*(2)	0.028561+N(5)
Dltcer	-8.966539(0)*	-8.878199*(7)	0.036675+N(4)
F1	-7.062396*(0)	-7.186081*(4)	0.032774+N(6)
F2	-9.126392*(0)	-8.848686*(9)	0.070676+N(5)

Fonte: Elaboração própria com base em dados da pesquisa.

Notas: Todos os modelos foram rodados utilizando constante e tendência conforme sugerido pela análise gráfica. Os gráficos das séries encontram-se no Apêndice A, Figura A-1.

As defasagens estão entre parênteses, * denota rejeição da hipótese nula a 1%. + N, denota não rejeição da hipótese nula a 1%.

Os resultados da Tabela 3 mostram evidências de que as séries são estacionárias. Desta forma pelo testes ADF e PP rejeitam-se a hipótese nula de raiz unitária para todas as séries ao nível de significância de 1%. Por outro lado o teste KPSS – tendo a hipótese nula inversa dos testes ADF e PP – não rejeita-se a hipótese nula de estacionariedades das séries, assim as séries são estacionárias a 1% de significância.

4.1 PREVISÕES DENTRO DA AMOSTRA

No que diz respeito a previsões dentro da amostra, existem diversos critérios concorrentes quando o propósito é avaliar o desempenho do modelo dentro da amostra. Os critérios de Informação de Akaike, Teste de razão de verossimilhança, Hannan-Quinn e Schwarz Bayesiano são exemplos de critérios de escolha de modelos dentro da amostra (LTKEPOHL, 2007 apud MENDONÇA, SACHSIDA; MEDRANO, 2013, p.10)

Para a análise dentro da amostra foi estimado 5 modelos de previsão da taxa de inflação⁷. O primeiro modelo (Modelo 1) refere-se a somente o uso de fatores para prever a taxa de inflação. No segundo modelo é usado somente o índice Geral de *Commodities* do FMI (Modelo 2);, terceiro modelo somente variáveis macroeconômicas fundamentais para a previsão da inflação (Modelo 3); no quarto modelo é utilizado variáveis macroeconômicas mais fatores (Modelo 4) e por fim no quinto e último modelo (Modelo 5) é usado variáveis macroeconômicas fundamentais com o índice de *commodities* geral do FMI. Como pode-se observar o exercício econométrico parte de um modelo mais desagregado para um modelo mais completo. Este exercício tem como finalidade tentar capturar o efeito dos fatores na previsão da inflação de forma a verificar a importância do uso dos fatores comuns nos modelos de previsões. Os resultados encontram-se na Tabela 4, a seguir:

Tabela 4: Resultados das Previsões dentro da Amostra

	Modelo 1s	Modelo 2	Modelo3	Modelo 4	Modelo 5
R²	1.00%	0.00%	3.49%	5.66%	3.51%
R² Ajustado	-0.80%	-0.90%	-0.12%	0.27%	-1.04%
Log (SSR)	0.492	0.496	0.473	0.463	0.473
Previsões (Forecast)	12.761	13.372	14.989	14.581	14.762

Fonte: Elaboração própria com base em dados da pesquisa.

Notas: Todos os modelos foram rodados utilizando os erros padrão robustos *Newey-West* (HAC).

A Tabela 4 encontra-se algumas medidas ajustamento dos modelos, como R², R² ajustado, logaritmo da soma de quadrado do resíduo (log (SSR)) e valores das previsões. Como se pode observar os modelos apresentaram baixo poder de previsão expresso pelo baixo R². Todavia o exercício tem como objetivo apenas analisar a inclusão de fatores comuns para um melhor ajustamento do modelo. Entre os modelos, o 4 e 5 são os que apresentaram melhores resultados, pois são modelos mais completos, levando

⁷ No Apêndice B, Quadro 1, tem-se uma a especificação dos modelos estimados.

em consideração a expectativa de inflação, os choques de demanda e de oferta, além do componente autorregressivo da taxa de inflação. Todavia entre os modelos, o4 e 5, apresentaram os melhores resultados, mostrando que a inclusão de fatores comuns melhora o ajustamento do modelo dentro da amostra em relação ao uso de o índice de *commodities* geral.

Tabela 5 - Teste de Causalidade de Granger Previsão Dentro da Amostra

Variável Dependente	Teste	Variáveis Excluídas					
DLIPCA		DLEXPINFLA	DLHIATO	DLTXCER	F1	F2	All
	Chi-sq	3.641671	1.063984	7.668829	5.46743	1.479667	17.61948
	DF	2	2	2	2	2	10
	Prob,	0.1619	0.5874	0.0216	0.0650	0.4772	0.0617
DLEXPINFLA		DLIPCAVARI	DLHIATO7	DLTXCER	F1	F2	All
	Chi-sq	8.431241	0.685228	1.364209	1.287453	7.491729	8.431241
	DF	2	2	2	2	2	2
	Prob,	0.0148	0.7099	0.5056	0.5253	0.0236	0.0285
DLHIATO7		DLIPCAVARI	DLEXPINFLA	DLTXCER	F1	F2	All
	Chi-sq	3.22915	8.449495	3.085445	15.02415	0.306214	42.76868
	DF	2	2	2	2	2	10
	Prob,	0.1990	0.0146	0.2138	0.0005	0.858	0.0000
DLTXCER		DLIPCAVARI	DLEXPINFLA	DLHIATO7	F1	F2	All
	Chi-sq	2.070271	1.32996	4.37341	5.250396	3.205069	14.08361
	DF	2	2	2	2	2	10
	Prob,	0.3552	0.5143	0.1123	0.0724	0.2014	0.1692
F1		DLIPCAVARI	DLEXPINFLA	DLHIATO7	DLTXCER	F2	All
	Chi-sq	0.426701	4.009986	4.900807	3.315454	8.791676	22.84869
	DF	2	2	2	2	2	10
	Prob,	0.8079	0.1347	0.0863	0.1906	0.0123	0.0113
F2		DLIPCAVARI	DLEXPINFLA	DLHIATO7	DLTXCER	F1	All
	Chi-sq	1.112405	3.484516	0.065225	4.055398	3.665446	16.38865
	DF	2	2	2	2	2	10
	Prob,	0.5734	0.1751	0.9679	0.1316	0.1600	0.0890

Fonte: Elaboração própria com base em dados da pesquisa.

De acordo com a Tabela 5, há evidências de que uma variação no câmbio causa, no sentido de Granger, uma variação no DLIPCA (em nível de significância de 5%). Também há evidência de que uma variação no câmbio causa, no sentido de Granger, uma variação em F1 (nível de significância de 10%). Isto é compreensível na medida em que variações na taxa de câmbio têm efeito de repasse cambial para os preços internos e um dos possíveis canais poderia ser via custo de produção através das elevações dos preços das *commodities* que são cotadas em dólar.

Uma variação em F1 causa, no sentido de Granger, uma variação na taxa de DLIPCA e na taxa de câmbio (nível de significância de 10%). Desta forma mostra que os fatores dos preços das *commodities* (F1) tendem a trazer informações para os preços internos e também pode afetar a taxa de câmbio⁸. O F2 causa, no sentido de Granger, uma variação na expectativa de inflação e no F1 (nível de significância de 5%), este resultado trás indícios que o F2 este mais relacionado ao lado das expectativas que são trazidas com as variações nos preços das *commodities*. Outra questão importante a se ressaltar é que não há uma relação inversa entre a taxa de inflação e os fatores, evidenciando que possíveis políticas macroeconômicas não teriam efeitos sobre os preços das *commodities*, desta maneira os preços das *commodities* podem conter um importante conteúdo informacional para tomada de decisão de política monetária.

Realizada a investigação dentro da amostra o próximo passo é extrapolar esta investigação para fora da amostra, dada que os resultados dentro da amostra não necessariamente representam os resultados das previsões fora da amostra.

⁸ Este resultado é interessante no sentido que fornece evidências prévias que o Brasil pode se constituir em um país cuja moeda pode ser denominada “*commodity currency*” para determinados produtos da sua pauta de exportação.

4.2 PREVISÕES FORA DA AMOSTRA (*N-STEP AHEAD OUT-OF-SAMPLE-FORECASTING*)

A previsão fora da amostra (*Out-of-sample*) é utilizada para determinar se um dos principais indicadores proposto é potencialmente útil para a previsão de um variável alvo. No caso do presente trabalho, tem-se como foco a variável alvo taxa de inflação e a utilização de fatores comuns como uma variável importante para predizer esta variável do ponto de vista de uma melhora do poder preditivo em relação ao índice de *commodities* geral.

O experimento fora da amostra consiste em fazer previsões com base em um subconjunto da amostra. Isto é, o total de dados é dividido em um conjunto de "*inicialização*" e um conjunto de "*teste*" ou "*validação*" definido. Em seguida, o conjunto de "*inicialização*" é utilizado para estimar os parâmetros e inicializar o método. As previsões são feitas para o conjunto de "*teste*"⁹. Uma vez que o conjunto de teste não foi utilizado no ajustamento do modelo, estas previsões são genuínas previsões feitas sem utilizar os valores das observações para este período. As medidas de precisão são calculadas para os erros no conjunto de teste definido apenas (MAKRIDAKIS; WHEELWRIGH;HYNDMAN;1998, Ch. 2).

Desta forma tem-se o primeiro período para o ajustamento do modelo e o outro período para a previsão. Assim dado o conjunto de observações T , sendo que $\{r_1, \dots, r_T\}$, divide-se o período para inicialização $\{r_1, \dots, r_n\}$ e o período para teste (previsão) $\{r_{n+1}, \dots, r_T\}$, onde n é a origem inicial previsão. O tamanho da amostra reservada para a previsão é aleatória, na literatura existem trabalhos que reservam 20%, 30% e até 50% do tamanho total da amostra, nesta pesquisa será utilizada no mínimo 20 observações para previsão fora da amostra.

Definido o subconjunto da amostra reservada para previsão, é necessário estabelecer um horizonte de previsão h passos à frente (*h step ahead out-sample-forecasting*), neste trabalho serão realizadas previsões para $h= 1, 3, 6, 9$ e 12 passos à frente. Também é necessário estabelecer uma função de perda para a previsão, que será a medida de acurácia do modelo.

O próximo passo é definir os modelos que serão utilizados, como já especificados para análise dentro da amostra, serão utilizados 8 diferentes modelos, os 5 modelos anteriores já mencionados e mais três especificações adicionais que são três modelos autorregressivos vetoriais (VARs). Para $M = n$ para a previsão inicial, há uma competição entre os modelos de forma a verificar qual deles oferece um maior poder de previsão. Os modelos são "*roll*" através do subconjunto de dados fora da amostra uma observação ao longo do tempo para cada período de previsão da variável alvo. Isto significa que os parâmetros dos modelos são reestimados com uma observação adicional aos seus dados de estimativa cada vez que prevê a variável alvo h passos à frente, esta interação ocorre até que $M = T$. Desta forma ao fazer previsões um passo a frente terá $T - n - 1$ (o número de observações para previsão vai diminuindo) e o horizonte de previsão esta aumentando $M - h + 1$.

Realizadas as previsões fora da amostra para diferentes horizontes, um passo final é verificar a acurácia do modelo. Existem diversas medidas estatísticas padrões de acurácia de modelos como erro médio (ME), erro absoluto médio (MAE) e o erro quadrado médio (MSE). Como cada uma destas estatísticas lida com medidas de precisão, cujo tamanho depende da escala dos dados, é difícil a comparação entre diferentes séries de tempo e para diferentes intervalos de tempo. Um das alternativas é usar medidas relativas ou de percentual, como erro percentual (PE), erro Percentual Médio (MPE) e erro percentual absoluto médio (MAPE)¹⁰, neste trabalho optou-se por usar como medida de acurácia dos modelos raiz do erro quadrado médio (RMSE) e MAPE. A Tabela 6 apresenta os resultados das previsões estáticas para $h= 1, 3, 6, 9$ e 12 passos à frente.

⁹ O subconjunto reservado para realizar as previsões *out-of-sample*.

¹⁰ Para uma discussão detalhada ver Makridakis, Wheelwright, and Hyndman (1998, Ch. 2).

Tabela 6 - Previsões Estáticas fora da Amostra para $h = 1, 3, 6, 9$ e 12 Passos a Frente

		<i>Horizonte de Previsão (Forecast horizon)</i>				
		<i>h=1</i>	<i>h=3</i>	<i>h=6</i>	<i>h=9</i>	<i>h=12</i>
Modelo 1	<i>RMSE</i>	0.13412	0.13412	0.13412	0.13412	0.13412
	<i>MAPE</i>	117.45	117.45	117.45	117.45	117.45
Modelo 2	<i>RMSE</i>	0.13737	0.13737	0.13737	0.13737	0.13737
	<i>MAPE</i>	108.83	108.83	108.83	108.83	108.83
Modelo 3	<i>RMSE</i>	0.14433	0.14617	0.14620	0.14620	0.14620
	<i>MAPE</i>	105.95	106.63	106.54	106.54	106.54
Modelo 4	<i>RMSE</i>	0.14208	0.14264	0.14269	0.14269	0.14269
	<i>MAPE</i>	122.19	115.38	115.34	115.34	115.34
Modelo 5	<i>RMSE</i>	0.14389	0.14566	0.14569	0.14569	0.14569
	<i>MAPE</i>	106.36	107.04	106.95	106.95	106.95
Modelo 6 VAR Fatores	<i>RMSE</i>	0.15272	0.13691	0.13308	0.13167	0.13178
	<i>MAPE</i>	180.97	125.88	148.51	147.59	147.91
Modelo 7 VAR commodities	<i>RMSE</i>	0.15215	0.13549	0.13232	0.13115	0.13123
	<i>MAPE</i>	203.54	117.59	135.65	135.50	135.39
Modelo 8 VAR índices	<i>RMSE</i>	0.15738	0.14697	0.13834	0.13629	0.13614
	<i>MAPE</i>	165.76	169.68	159.05	156.62	156.81

Fonte: Elaboração própria com base em dados da pesquisa.

Notas: Todos os modelos foram rodados utilizando os erros padrão robustos *Newey-West* (HAC).

Como pode se observar na Tabela 6, os primeiros 5 modelos são modelos dinâmicos de equação única (uniquacionais), enquanto os três últimos modelos são modelos autorregressivos vetoriais (VARs). Os modelo 1 tem um menor RMSE em relação aos modelos 2 e 3, todavia não tem um menor MAPE. O modelo 4 também apresentou um RMSE menor que o modelo 5. Entre os modelos Vars, o modelo 6 apresentou menor RMSE e MAPE. Desta forma os modelos 1, 4 e 6 mostraram-se superiores aos demais em termos de poder preditivo, tendo em comum o uso de fatores comuns.

A Tabela 7 apresenta uma comparação entre previsões estáticas e dinâmicas para o horizonte de previsão um passo a frente fora da amostra.

Tabela 7 - Comparação entre Previsão Estática e Dinâmica para Horizonte de Previsão 1 Passo à Frente

		<i>Previsão Estática</i>	<i>Previsão dinâmica</i>
		<i>Horizonte de Previsão 1 Passo a Frente</i>	
Modelo 1	<i>RMSE</i>	0.13412	0.13364
	<i>MAPE</i>	117.45	115.46
Modelo 2	<i>RMSE</i>	0.13737	0.13677
	<i>MAPE</i>	108.83	107.77
Modelo 3	<i>RMSE</i>	0.14433	0.14620
	<i>MAPE</i>	105.95	106.54
Modelo 4	<i>RMSE</i>	0.14208	0.14269
	<i>MAPE</i>	122.19	115.34
Modelo 5	<i>RMSE</i>	0.14389	0.14569
	<i>MAPE</i>	106.36	106.95
Modelo 6	<i>RMSE</i>	0.15272	0.13179
	<i>MAPE</i>	180.97	147.90
Modelo 7	<i>RMSE</i>	0.15215	0.13122
	<i>MAPE</i>	203.54	135.40
Modelo 8	<i>RMSE</i>	0.15738	0.13618
	<i>MAPE</i>	165.76	156.74

Fonte: Elaboração própria com base em dados da pesquisa.

Notas: Todos os modelos foram rodados utilizando os erros padrão robustos *Newey-West* (HAC).

Os resultados da Tabela 7 mostram evidências que previsão dinâmica na maioria dos modelos conduz a um RMSE e MAPE menor do que a previsão estática para $h=1$. Outra conclusão é que os modelos que utilizaram fatores comuns produzem melhores previsões em relação aos outros modelos.

A Tabela 8 apresenta previsão recursiva para diferentes horizontes de previsão como forma de verificar a robustez dos resultados obtidos.

Tabela 8 - Previsões Recursivas fora da Amostra para $h = 1, 3, 6, 9$ e 12 Passos a Frente

		<i>Horizonte de Previsão (Forecast horizon)</i>				
		<i>h=1</i>	<i>h=3</i>	<i>h=6</i>	<i>h=9</i>	<i>h=12</i>
Modelo 1	<i>RMSE</i>	0.13364	0.13364	0.13364	0.13364	0.13364
	<i>MAPE</i>	115.46	115.46	115.46	115.46	115.46
Modelo 2	<i>RMSE</i>	0.13677	107.77	0.13677	0.13677	0.13677
	<i>MAPE</i>	107.77	107.7	0.13677	107.77	107.77
Modelo 3	<i>RMSE</i>	0.14433	0.14617	0.14620	0.14620	0.14620
	<i>MAPE</i>	105.95	106.63	106.54	106.54	106.54
Modelo 4	<i>RMSE</i>	0.14208	0.14264	0.14269	0.14269	0.14269
	<i>MAPE</i>	122.19	115.38	115.34	115.34	115.34
Modelo 5	<i>RMSE</i>	0.14389	0.14566	0.14569	0.14569	0.14569
	<i>MAPE</i>	106.36	107.04	106.95	106.95	106.95
Modelo 6	<i>RMSE</i>	0.15272	0.13691	0.13308	0.13167	0.13178
	<i>MAPE</i>	180.97	125.88	148.51	147.59	147.91
Modelo 7 VAR Commodities	<i>RMSE</i>	0.15215	0.13549	0.13232	0.13115	0.13123
	<i>MAPE</i>	203.54	117.59	135.65	135.50	135.39
Modelo 8 índices	<i>RMSE</i>	0.15738	0.14697	0.13834	0.13629	0.13614
	<i>MAPE</i>	165.76	169.68	159.05	156.62	156.81

Fonte: Elaboração própria com base em dados da pesquisa.

Notas: Todos os modelos foram rodados utilizando os erros padrão robustos *Newey-West* (HAC).

Os resultados da Tabela 8 corroboram os resultados anteriores na medida em que os modelos que utilizam fatores apresentaram um melhor poder preditivo. Este fato pode ser decorrente que o uso de fatores comuns possibilita capturar componentes não observáveis da amostra. Outra vantagem refere-se que possibilita reduzir o número de parâmetros a ser estimado, desta forma evitando uma parametrização de modelos do tipo VAR.

5 CONSIDERAÇÕES FINAIS

O presente trabalho buscou verificar se a inclusão de fatores contidos nos índices de *commodities* melhora o desempenho preditivo de um modelo para inflação que contenha somente variáveis econômicas. Primeiramente foram estimados fatores comuns que posteriormente foram utilizados nas previsões. Seguindo a abordagem de Chen, Rogoff e Rossi (2008), Ferraro, Rogoff e Rossi (2012), buscou-se através de várias especificações de modelos, partindo do particular para o geral verificar a contribuição do uso de fatores comuns na previsão de um modelo de inflação. Para isto realizou-se previsões dentro e fora da amostra.

Os resultados mostraram evidências que o uso de fatores comuns melhora o poder preditivo dos modelos, tanto dentro como fora da amostra. Isto decorre por razões como a utilização de fatores comuns possibilita capturar componentes não observáveis do conjunto de dados, possibilita utilizar grande conjunto de informações em modelos do tipo VAR sem conduzir a uma parametrização do modelo.

REFERÊNCIAS

- ALMEIDA, Glaudiane; ALVES, Paloma; LIMA, Elcyon. Impactos dos Choques na Política Monetária e no Câmbio no Brasil: Um Modelo de Autorregressão Vetorial Estrutural Aumentada por Fatores Dinâmicos. *IPEA*, Texto para Discussão, No. 1711, Fev., 2012.
- AWOKUSE, T.O.; YANG, J., 2003. The information role of commodity prices in formulating monetary policy: a re-examination. *Econ.Lett.* 79, 219–224.
- BAI, Jushan; NG, Serena. Determining the Number of Factors in Approximate Factor Models. *Econometrica*, Vol. 70, No. 1, pp. 191-221, Janeiro 2002.
- BANERJEE, Anindya; MARCELINO, Massimiliano; MASTEEN, Igor. Forecasting Macroeconomic Variables Using Diffusion Indexes in Short Samples with Structural Change. *EUI Working Paper ECO 2008/17*. EUROPEAN UNIVERSITY INSTITUTE, Departamento of Economics.
- BARSKY, R.B., KILIAN, L. *Do We Really Know That Oil Caused the Great Stagflation? A Monetary Alternative*. NBER, Working Paper 8386, 2001.
- BHAR, Ramaprasad., HAMORI, Shingeyuki. Information content of commodity futures prices for monetary policy. *Econ.Model.* 25, p. 274–283, 2008.
- BLOOMBERG, S. Brock.; HARRIS, Ethan S. “The Commodity-Consumer Prices Connection: Fact or Fable?” Federal Reserve Bank of New York *Economic Policy Review*, 1 (3), p. 21–38 .October, 1995.
- BUENO, R. L. S. *Econometria de séries temporais*. 1. ed. São Paulo: Cengage, 2008. v. 1. 299 p.
- CHEN, Yu-Chin.; ROGOFF, Kenneth.; ROSSI, Barbara. CAN EXCHANGE RATES FORECAST COMMODITY PRICES? NBER. *Working Paper*, 13901. Disponível em: <<http://www.nber.org/papers/w13901>>. Acesso 20 mai. 2014
- CHEUNG, Calista. Are commodity prices useful leading indicators of inflation? *Working Paper*, Bank of Canada, 2009. Disponível <<http://www.bankofcanada.ca/wp-content/uploads/2010/01/dp09-5.pdf>>. Acesso em: 2 dez. 2013.
- CINER, Cetin. Commodity prices and inflation: Testing in the frequency Domain. *Research in International Business and Finance.*, 25 (2011), p. 229-237.
- CODY, Brian J.; MILLS, Leonardo O. The role of commodity prices in formulating monetary policy. *Rev. Econ. Stat.*, v. 73, no. 2, , p.358-365, May, 1991. Disponível em: <<http://www.jstor.org/stable/2109529>>. Acesso em: 4 nov. 2013.
- COOK, Steven. Spurious rejection by cointegration tests incorporating structural change in the cointegrating relationship. *Applied Economics Letters*, n. 11, p. 879-884, 2004.
- DICKEY, D. A.; FULLER, W. A. Distribution of the estimators for autoregressive time series with a unit root. *J. Am. Stat. Assoc.*, Alexandria, v. 74, no. 366, p. 427-431, Jun. 1979.
- Doornik, J. A. and D. F. Hendry (1992). PCGIVE 7: Empirical Econometric Modelling PcGiveTM 14: Vol I. Oxford: Institute of Economics and Statistics, University of Oxford

_____. PCGIVE 7: Modeling Dynamic Systems PcGiveTM 14: Vol II. Oxford: Institute of Economics and Statistics, University of Oxford.

ENDERS, W. *Applied econometric time series*. New York: John Wiley & Sons, 1995.

ENGLE, R. F. GRANGER, Clive, W. J. Cointegration and error correction: representation, estimation and testing. *Econometrica*, Chicago, v. 55, no. 2, p. 251-276, 1987.

FELÍCIO, Wilson R. de. O.; ROSSI JUNIOR, José L. Common Factors and the Exchange Rate: Results From The Brazilian Case. *RBE*, v.68, n.1, p. 49-71. Jan-Mar 2014.

FERREIRA, Roberto T. *Forecasting quarterly Brazilian GDP growth rate with linear and nonlinear diffusion index models*. 2005.110f. Tese (Doutorado em Economia) - Universidade Federal do Ceará, Fortaleza, 2005.

FERREIRA, Roberto T.; OLIVEIRA JÚNIOR, José N. de.; CASTELAR, Ivan. Modelos de Índice de Difusão para prever a taxa de crescimento do PIB agrícola brasileiro. *Nova Economia*, Belo Horizonte, v.22, n. 1, p. 117-139, _janeiro-abril de 2012.

FORNI, Mario; HALLIN, Marc; LIPPI, Marco; REICHLIN, Lucrezia. The Generalized Dynamic-Factor Model: Identification and Estimation. *The Review of Economics and Statistics*, Vol. 82, No. 4, pp. 540-554, Nov., 2000.

FERRARO, Domenico.; ROGOFF Kenneth S.; ROSSI, Barabara. *Can oil prices forecast exchange rates?*. NBER, 2012. Working Paper 17998. Disponível em: <<http://www.nber.org/papers/w17998>>. Acesso em 20 mai. 2014.

FRANKEL, Jeffrey A. *The effect of monetary policy on real commodity prices*. NBER Working Paper, no. W12713, 2006.

FURLONG, Fred.; INGENITO, Robert. “Commodity Prices and Inflation”, *FRBSF Economic Review* 2 (1996), 27–47.

GARNER, Alan C. Commodity Prices: Policy Target or Information Variable? *Journal of Money, Credit, and Banking*., Ohio State University Press, v. 21, no 4, p. 508–514, Nov. 1989. Disponível em: <<http://www.jstor.org/stable/1992357>>. Acesso: 04/11/2013.

GOSPODINOV, Nikolay.; NG, Serena. Commodity prices, convenience yields, and inflation. *The Review of Economics and Statistics*, 95(1), p.206-219, Mar, 2013.

GREENE, W. H. *Econometric analysis*. 6th ed. New Jersey: Prentice Hall, 2008.

HASSAN, A.F.M. Kamrul; SALIM, Ruhul A. Is there any link between commodity price and monetary policy? Evidence from Australia. *Economic Analysis and Policy*. 41 (3): pp. 205-216, 2011.

INSTITUTO DE PESQUISA ECONÔMICA APLICADA. Macroeconômico. 2009. Disponível em: <<http://www.ipeadata.gov.br>>. Acesso em: 03 mar. 2014.

LORENA, Vicini. *Análise multivariada da teoria à prática*. Santa Maria : UFSM, CCNE, , 215 p., 2005.

- MAEDA JUNIOR, Tomoharu. *Prevendo a Taxa de Juros no Brasil: Uma Abordagem Combinada entre o Modelo de Correção de Erros e o Modelo de Fatores*. 2012. 74 f. Dissertação (MPFE) - Escola de Economia de São Paulo. 2012.
- MAKRIDAKIS, Spyros.; WHEELWRIGHT Steven. C.; and HYNDMAN Rob C. *Forecasting: Methods and Applications*. 3rd. ed. New York: John Wiley and Sons, 1998.
- MARQUIS, M.H., CUNNINGHAM, S.R., 1990. Is there a role for commodity prices in the design of monetary policy? Some empiricalevidence. *Southern Econ. J.* 57, 169–209.
- MENDONÇA, Jorge C. de; SACHSIDA, Adolfo.; MEDRANO, Luis A. T. UM MODELO ECONOMETRICO PARA PREVISÃO DE IMPOSTOS NO BRASIL. *Economia Aplicada*, v. 17, n. 2, p. 295-329, 2013.
- REGAZZI, A. J. INF 766 - *Análise multivariada*. Viçosa: Universidade Federal de Viçosa, Centro de Ciências Exatas e Tecnológicas. Departamento de Informática, 2001. 166p. Apostila de disciplina.
- REIS, E. *Estatística multivariada aplicada*. Lisboa, 1997.
- SAID, S. E.; DICKEY, D. A. Testing for unit roots in autoregressive moving average models of unknown order. *Biometrika*, London, v. 71, no. 3, p. 599-607, 1984.
- STOCK, James H.; WATSON, Mark W. *Diffusion Indexes*: NBER, 1998. Working Paper Series, n.6702.
- _____. Forecasting Using Principal Components From a Large Number of Predictors. *Journal of the American Statistical Association*, Vol. 97, No. 460, pp. 1167-1179, Dez. 2002.
- _____. Macroeconomic forecasting using diffusionindexes. *Journal of Business and Economic Statistics*, Vol. 20, No. 2, pp. 147-162, Abr. 2002. Disponível: <<http://www.jstor.org/stable/3085839>>. Acesso em 15 de out. 2013.

APÊNDICE A– DESCRIÇÃO E ESTATÍSTICA DESCRITIVA DOS DADOS

Tabela A.1 – Descrição dos Dados

Variáveis	Descrições	Transformação	Sigla	Fonte
Preços de todas as <i>Commodities</i>	Índice de preços de todas as <i>commodities</i> , 2005 = 100, inclui tanto índice de preços combustível e não-combustível	Diferença do logaritmo	DLPALLFNF	FMI
Preços não combustível	Índice de Preços não-combustível, 2005 = 100, inclui alimentos e bebidas e índice de preços industrial.	Diferença do logaritmo	DLPNFUEL	FMI
Preços de alimento e Bebidas	Índice de Preços de Alimentos e Bebidas de 2005 = 100, inclui índice de preços de Alimentos e Bebidas.	Diferença do logaritmo	DLPFANDB	FMI
Preços de Bebidas	Índice de Preços Bebidas, 2005 = 100, inclui café, chá e cacau	Diferença do logaritmo	DLPBEVE	FMI
Preços de insumos industriais	Índice de Preços de insumos industriais de 2005 = 100, inclui índice de preços de matérias primas agrícolas e índice de preços de metais.	Diferença do logaritmo	DLPINDU	FMI
Preços de matérias primas Agrícolas	índice de matérias primas agrícolas, 2005=100, inclui índice de preços da madeira, algodão, lã, borracha, e couro cru.	Diferença do logaritmo	DLPRAWM	FMI
Preços de metais	Índice de Preços Metais, 2005 = 100, inclui índice de preços de cobre, alumínio, minério de ferro, estanho, níquel, zinco, chumbo e urânio.	Diferença do logaritmo	DLMETA	FMI
Preços Energia	Índice de combustível (energia), 2005 = 100, inclui índice de preços de óleo cru (petróleo), gás natural e carvão	Diferença do logaritmo	DLPNRG	FMI
Preços Petróleo	Índice de preços Petróleo bruto (petróleo), 2005 = 100, média simples dos três preços à vista; Datação Brent, West Texas Intermediate, e Dubai	Diferença do logaritmo	DLPOILAPSP	FMI
Preços aos Consumidor	Índice nacional de preços ao consumidor-amplo (IPCA) - Var. % mensal	Acréscimo da constante (1) a série e feito a Diferença do logaritmo	DLIPCAvar	IBGE/BCB
Taxa de Câmbio	Índice da taxa de câmbio efetiva real (IPCA) - Jun/1994=100 – Índice	Diferença do logaritmo	DLTXCER	BCB
Expectativa de inflação	Expectativa média de Inflação - IPCA - taxa anualizada para os próximos seis meses - (% a.a.)	Diferença do Logaritmo	DLexpinfla	BCB
Índice de Atividade Econômica	Índice de Atividade Econômica do Banco Central (IBC-Br) - com ajuste sazonal	Acréscimo de uma constante (7) ao Hiato do IBC-Br e feito a diferença do logaritmo	DLhiato	BCB

Tabela A.2 – Estatística descritiva dos Índices de *Commodities* – Média, desvio padrão e matriz de correlação.

Média e desvio Padrão	
0.005444	0.033128
0.005136	0.033027
0.005241	0.034257
0.004204	0.042012
0.005803	0.042448
0.002857	0.031984
0.008299	0.054857
0.009065	0.070092
0.009249	0.080854

Matriz de correlação									
	DLPNFUEL	DLPFANDB	DLPFOOD	DLPBEVE	DLPINDU	DLPRAWM	DLPMETA	DLPNRG	DLPOILAPSP
DLPNFUEL	1.00	0.83	0.82	0.51	0.90	0.62	0.87	0.63	0.62
DLPFANDB	0.83	1.00	0.99	0.55	0.51	0.39	0.49	0.51	0.50
DLPFOOD	0.82	0.99	1.00	0.46	0.50	0.38	0.48	0.51	0.50
DLPBEVE	0.51	0.55	0.46	1.00	0.37	0.27	0.35	0.28	0.27
DLPINDU	0.90	0.51	0.50	0.37	1.00	0.68	0.97	0.58	0.58
DLPRAWM	0.62	0.39	0.38	0.27	0.68	1.00	0.48	0.49	0.48
DLPMETA	0.87	0.49	0.48	0.35	0.97	0.48	1.00	0.54	0.54
DLPNRG	0.63	0.51	0.51	0.28	0.58	0.49	0.54	1.00	0.99
DLPOILAPSP	0.62	0.50	0.50	0.27	0.58	0.48	0.54	0.99	1.00

APÊNDICE B – MODELOS DE PREVISÃO

$Modelo1 = DLIPCAvar1 = - 0.009937 - 0.008087 * F1 - 0.01436 * F2$ $(SE) \quad (0.0158) \quad (0.0149) \quad (0.0156)$
$Modelo2 = DLIPCAvar1 = - 0.009839 + 0.01074 * DLPALLFNF$ $(SE) \quad (0.016) \quad (0.283)$
$Modelo3 = DLIPCAvar1 = - 0.1073 * DLIPCAvar1_1 - 0.005084 - 0.1135 * DLexpinfla$ $(SE) \quad (0.0959) \quad (0.016) \quad (0.208)$ $+ 0.0676 * DLhiato7 + 0.7442 * DLTXCER$ $(0.0508) \quad (0.53)$
$Modelo4 = DLIPCAvar1 = - 0.1261 * DLIPCAvar1_1 - 0.004436 - 0.1015 * DLexpinfla$ $(SE) \quad (0.0966) \quad (0.016) \quad (0.208)$ $+ 0.07714 * DLhiato7 + 0.9272 * DLTXCER - 0.01118 * F1$ $(0.0555) \quad (0.56) \quad (0.0168)$ $- 0.02234 * F2$ (0.0162)
$Modelo5 = DLIPCAvar1 = - 0.1071 * DLIPCAvar1_1 - 0.005358 - 0.1153 * DLexpinfla$ $(SE) \quad (0.0964) \quad (0.0162) \quad (0.209)$ $+ 0.06523 * DLhiato7 + 0.7689 * DLTXCER + 0.04859 * DLPALLFNF$ $(0.0533) \quad (0.556) \quad (0.315)$
$Modelo6 = VARFator = \pi_i = \alpha + \beta_1 \pi_{i-p} + \phi_2 \pi_{i+h}^e + \gamma_3 y_{i-p} + \psi_4 F_{i-p} + \delta_5 EP + \mu_i$
$Modelo7 = VARindGera1 = \pi_i = \alpha + \beta_1 \pi_{i-p} + \phi_2 \pi_{i+h}^e + \gamma_3 y_{i-p} + \psi_4 PALLFNF_{i-p} + \delta_5 EP + \mu_i$
$Modelo8 = VARindices = \pi_i = \alpha + \beta_1 \pi_{i-p} + \phi_2 \pi_{i+h}^e + \gamma_3 y_{i-p} + \psi_4 IndPC_{i-p} + \delta_5 EP + \mu_i$

Quadro B1 - Modelos de Previsão